

Multimodal Deepfake Speech Detection

Σύγκριση Στρατηγικών Audio-Visual Fusion

στο FakeAVCeleb v1.2

Γκάρο Αριστοτέλης (mtn2503)

Πλέσσας Γιώργος (mtn2524)

Τσαγκέτας Ορέστης (mtn2527)

Ιούνιος 2026

Περίληψη

Η ανίχνευση deepfake βίντεο αποτελεί κρίσιμη πρόκληση της σύγχρονης επεξεργασίας πολυμέσων, με άμεσες επιπτώσεις στην αξιοπιστία των ψηφιακών μέσων. Στην παρούσα εργασία αναπτύσσουμε και αξιολογούμε ένα πολυτροπικό σύστημα που εκμεταλλεύεται ταυτόχρονα ακουστική και οπτική πληροφορία για τον εντοπισμό παραποιήσεων. Σχεδιάζουμε και συγκρίνουμε συστηματικά δέκα διαφορετικές αρχιτεκτονικές, εξερευνώντας εναλλακτικές μεθόδους εξαγωγής χαρακτηριστικών και στρατηγικές συνδυασμού των δύο modalities. Τα πειράματα διεξάγονται στο FakeAVCeleb v1.2, ένα benchmark dataset με τέσσερις κατηγορίες παραποίησης που καλύπτουν συνδυασμούς αυθεντικού και συνθετικού ήχου/βίντεο. Ιδιαίτερη προσοχή δίνεται στην αντιμετώπιση της ακραίας ανισορροπίας κλάσεων του dataset και στην επιλογή κατάλληλων μετρικών αξιολόγησης. Τα αποτελέσματα αναδεικνύουν ότι το ακουστικό modality κυριαρχεί στο συγκεκριμένο task, ενώ η αποτελεσματικότητα της σύντηξης εξαρτάται κρίσιμα από την ποιότητα των οπτικών χαρακτηριστικών.

1 Εισαγωγή

Τα deepfake βίντεο, δηλαδή βίντεο στα οποία το πρόσωπο ή/και η φωνή ενός ατόμου έχει αντικατασταθεί συνθετικά, αποτελούν αυξανόμενη απειλή για την αξιοπιστία των οπτικοακουστικών μέσων. Η ανίχνευσή τους έχει εξελιχθεί σε ένα από τα κεντρικά προβλήματα της σύγχρονης υπολογιστικής έρευνας.

Τα πρώτα συστήματα ανίχνευσης αντιμετώπιζαν το πρόβλημα αποκλειστικά στο οπτικό επίπεδο, αναζητώντας τεχνητά artifacts στα frames του βίντεο. Ωστόσο, η ύπαρξη τεσσάρων διακριτών κατηγοριών παραποίησης (ψεύτικο πρόσωπο ή/και ήχος, ανεξάρτητα) καθιστά αναγκαία τη **πολυτροπική** (multimodal) προσέγγιση: η ταυτόχρονη εξέταση ήχου και εικόνας επιτρέπει την ανίχνευση παραποιήσεων που ένα μόνο modality δεν μπορεί να εντοπίσει.

Η παρούσα εργασία πραγματεύεται τα εξής ερωτήματα:

1. Ποιο audio feature extractor αποδίδει καλύτερα: εξειδικευμένα handcrafted features ή self-supervised μοντέλα (wav2vec2, HuBERT);
2. Βοηθάει η fusion ή μπορεί να αποσταθεροποιήσει την εκπαίδευση;
3. Πώς αντιμετωπίζεται αποτελεσματικά η ακραία ανισορροπία κλάσεων (42:1);
4. Ποιες περιοχές ήχου και προσώπου επηρεάζουν περισσότερο την απόφαση του μοντέλου;

Η εργασία οργανώνεται ως εξής: ορίζουμε το dataset (§2), παρουσιάζουμε τη μεθοδολογία (§3), αναλύουμε το πρόβλημα ανισορροπίας και τις αποφάσεις που ελήφθησαν (§4), παρουσιάζουμε τα αποτελέσματα (§5), εξετάζουμε την ερμηνευσιμότητα (§6), και καταλήγουμε σε συμπεράσματα (§7).

2 Dataset: FakeAVCeleb v1.2

2.1 Περιγραφή

Το FakeAVCeleb v1.2 [1] είναι ένα benchmark dataset για την αξιολόγηση πολυτροπικών συστημάτων ανίχνευσης deepfake. Αποτελείται από 21.566 βίντεο, οργανωμένα σε τέσσερις κατηγορίες που αντιστοιχούν στους πιθανούς συνδυασμούς αυθεντικού και παραποιημένου audio/video:

- **RealVideo-RealAudio (RVRA)**: αυθεντικό βίντεο και ήχος — η «πραγματική» κλάση
- **FakeVideo-FakeAudio (FVFA)**: συνθετικό πρόσωπο (face swap/reenactment) και συνθετικός ήχος
- **FakeVideo-RealAudio (FVRA)**: συνθετικό πρόσωπο, πρωτότυπος ήχος
- **RealVideo-FakeAudio (RVFA)**: αυθεντικό πρόσωπο, συνθετικός ήχος (TTS/voice swap)

Το dataset χωρίστηκε σε σύνολα εκπαίδευσης, επικύρωσης και ελέγχου με αναλογία **70%/15%/15%** και stratified sampling ανά κατηγορία, ώστε να διατηρηθεί η κατανομή κλάσεων σε κάθε σύνολο.


2.2 Ανισορροπία Κλάσεων

Το dataset παρουσιάζει ακραία ανισορροπία: οι κλάσεις fake (FVFA, FVRA, RVFA) υπερτερούν της real (RVRA) σε αναλογία **42:1**. Από τα 21.566 βίντεο, μόλις ~500 ανήκουν στην κλάση real. Το πρόβλημα αυτό έχει άμεσες συνέπειες στην αξιολόγηση: ένα μοντέλο που προβλέπει όλα τα δείγματα ως «fake» επιτυγχάνει:

- Accuracy $\approx 97,6\%$ (42 στα 43 δείγματα «σωστά»)
- F1 $\approx 0,98$ (στην κυρίαρχη κλάση fake)
- AUC $\approx 0,50$ — τυχαία ταξινόμηση

Αυτή η αντίφαση αποκαλύπτει γιατί **το AUC αποτελεί τη μόνη αξιόπιστη μετρική** για ανισόρροπα datasets: αξιολογεί την ικανότητα κατάταξης ανεξάρτητα από το threshold, χωρίς να επηρεάζεται από την κατανομή κλάσεων.

Τα σχήματα 1 απεικονίζουν την κατανομή κλάσεων και κατηγοριών.



Σχήμα 1: Κατανομή κλάσεων στο FakeAVCeleb v1.2.

3 Μεθοδολογία

3.1 Προεπεξεργασία Ήχου

Ο ήχος εξάγεται από τα αρχεία MP4 μέσω torchaudio και υφίσταται τα εξής βήματα:

1. Μετατροπή σε mono (μέσος όρος καναλιών)
2. Resample στα **16 kHz**
3. Αφαίρεση σιωπής (trim silence, librosa, top_db=20)
4. Κανονικοποίηση πλάτους στο $[-1, 1]$

Αποτέλεσμα: tensor διάστασης $(1, T)$.

3.2 Εξαγωγή Ακουστικών Χαρακτηριστικών

Χρησιμοποιήθηκαν τρεις εναλλακτικές μέθοδοι, μία ανά πείραμα:

Handcrafted Features (536 διαστάσεις). Εξειδικευμένα χαρακτηριστικά με έμφαση στη φωνητική και φασματική δομή:

- **MFCC** (40 συντελεστές) + 1η παράγωγος (Δ) + 2η παράγωγος ($\Delta\Delta$)
- **Φασματικά:** centroid, bandwidth, flux, rolloff, contrast (7 ζώνες)
- **ZCR** (Zero Crossing Rate) + RMS energy
- **F0** (βασική συχνότητα, parselmouth)
- Στατιστικά ανά χαρακτηριστικό: μέση τιμή, ελάχιστο, μέγιστο, τυπική απόκλιση

wav2vec 2.0 (768 διαστάσεις). Χρησιμοποιείται το pretrained μοντέλο wav2vec2-base χωρίς fine-tuning. Εξάγεται το τελευταίο hidden layer και εφαρμόζεται mean pooling κατά τον χρονικό άξονα. Το wav2vec2 εκπαιδεύεται με contrastive learning σε masked τμήματα του σήματος.

HuBERT (768 διαστάσεις). Χρησιμοποιείται το hubert-base-ls960 με mean pooling στο τελευταίο hidden layer. Το HuBERT εκπαιδεύεται με masked prediction σε διακριτές κατηγορίες που προέκυψαν από offline clustering του σήματος.

3.3 Προεπεξεργασία Video

Τα frames εξάγονται από κάθε βίντεο με OpenCV VideoCapture και uniform sampling (μέγιστο 100 frames). Το χρωματικό κανάλι μετατρέπεται από BGR σε RGB.

3.4 Εξαγωγή Οπτικών Χαρακτηριστικών — Landmarks (731 διαστάσεις)

Χρησιμοποιείται το face_alignment με **68 σημεία** ανά frame, οργανωμένα σε 4 γεωμετρικές περιοχές:

- **Μάτια:** EAR (Eye Aspect Ratio), blink rate, ασυμμετρία
- **Jaw:** θέση, συμμετρία γνάθου
- **Φρύδια:** ταχύτητα κίνησης, ασυμμετρία
- **Στόμα:** MAR (Mouth Aspect Ratio), άνοιγμα

Για κάθε χαρακτηριστικό υπολογίζονται: μέση τιμή, ελάχιστο, μέγιστο, τυπική απόκλιση σε όλα τα frames.

3.5 Στρατηγικές Σύντηξης (Fusion)

Δοκιμάστηκαν τέσσερις στρατηγικές:

- **Unimodal Audio:** μόνο ακουστικά χαρακτηριστικά $\rightarrow$ MLP
- **Unimodal Video:** μόνο οπτικά χαρακτηριστικά $\rightarrow$ MLP
- **Early Fusion:** εφαρμογή PCA στο οπτικό διάνυσμα για ευθυγράμμιση διαστάσεων με το ακουστικό, ακολουθεί συνένωση (concatenation) $\rightarrow$ ένα κοινό MLP. Το PCA αποτρέπει την αριθμητική υπεροχή του οπτικού vector (ιδίως σε μελλοντική χρήση Xception 2048d) έναντι του ακουστικού.
- **Late Fusion:** δύο ανεξάρτητα MLP $\rightarrow$ σταθμισμένος μέσος:

$$s_{\text{final}} = w \cdot s_{\text{audio}} + (1 - w) \cdot s_{\text{video}}, \quad w = 0,7 \quad (1)$$

3.6 Αρχιτεκτονική MLP

Η ίδια αρχιτεκτονική MLP χρησιμοποιείται παντού:

$$\text{Linear}(d \rightarrow 256) \xrightarrow{\text{ReLU+Dropout}} \text{Linear}(256 \rightarrow 128) \xrightarrow{\text{ReLU+Dropout}} \text{Linear}(128 \rightarrow 1) \xrightarrow{\text{Sigmoid}} s \in [0, 1]$$

όπου d η διάσταση των εισερχόμενων χαρακτηριστικών.

4 Αντιμετώπιση Ανισορροπίας Κλάσεων

4.1 Αποτελέσματα Baseline (Run 1) — Αναγνώριση Προβλήματος

Στο πρώτο run εκπαίδευσης (αναφέρεται ως *baseline*) εφαρμόστηκε μόνο WeightedRandomSampler. Ο πίνακας 1 παρουσιάζει τα αποτελέσματα ταξινομημένα κατά AUC.

Πείραμα	AUC	EER	F1	ACC
Early (HC+LM)	0.9322	0.1616	0.9786	0.9586
Audio-only (HC)	0.9274	0.1496	0.9645	0.9323
Late (HC+LM)	0.9255	0.1573	0.9881	0.9765
Audio-only (W2V)	0.9122	0.1999	0.9802	0.9617
Audio-only (HuB)	0.9074	0.2001	0.9750	0.9518
Late (W2V+LM)	0.8896	0.1895	0.9878	0.9759
Late (HuB+LM)	0.8724	0.1849	0.9880	0.9765
Early (W2V+LM)	0.7697	0.2902	0.9883	0.9768
Early (HuB+LM)	0.6983	0.3985	0.9883	0.9768
Video-only (LM)	0.5712	0.4295	0.9881	0.9765

Πίνακας 1: Run 1 (baseline). HC=Handcrafted, W2V=wav2vec2, HuB=HuBERT, LM=Landmarks.

Τα πειράματα 08, 10 και 04 εμφανίζουν **F1 $\approx$ 0,98-0,99 με AUC = 0,57-0,77**. Αυτή η αντίφαση αποκαλύπτει το πρόβλημα: τα μοντέλα προβλέπουν σχεδόν τα πάντα ως «fake» και παρουσιάζουν τεχνητά υψηλή F1/ACC, ενώ δεν έχουν μάθει τίποτα ουσιαστικό (AUC $\approx$ τυχαίο). Αυτό ήταν το έναυσμα για τις αλλαγές του Run 2.

4.2 Λύση 1 — WeightedRandomSampler

Υπήρχε ήδη στο baseline. Εξισορροπεί κατά τη sampling τη σχέση fake:real από **42:1 $\rightarrow$ 5:1** ανά batch: κάθε batch περιέχει στατιστικά 5 fake δείγματα για κάθε 1 real. Δεν αλλάζει το test set, μόνο την κατανομή κατά την εκπαίδευση.

4.3 Λύση 2 — BCEWithLogitsLoss με pos_weight = 0,2

Ακόμη και με WeightedRandomSampler, το υπολειπόμενο 5:1 ratio ανά batch προκαλεί ανισορροπία στη συνάρτηση απώλειας:

$$\begin{aligned} \text{χωρίς pos_weight: } 5 \times \mathcal{L}_{\text{fake}} + 1 \times \mathcal{L}_{\text{real}} &\Rightarrow \text{το fake κυριαρχεί 5:1} \\ \text{με pos_weight = 0,2: } 5 \times 0,2 \times \mathcal{L}_{\text{fake}} + 1 \times 1,0 \times \mathcal{L}_{\text{real}} &= \mathcal{L}_{\text{fake}} + \mathcal{L}_{\text{real}} \quad \checkmark \end{aligned}$$

Η τιμή $\text{pos_weight} = 1/\text{target_ratio} = 1/5 = 0,2$ δεν είναι αυθαίρετη: αποτελεί τη μαθηματικά μοναδική ορθή επιλογή που εξουδετερώνει ακριβώς το υπολειπόμενο 5:1 gradient imbalance, ώστε κάθε κλάση να συνεισφέρει ισότιμα στην ενημέρωση βαρών.

4.4 Λύση 3 — Late Fusion Weight: 0,5 $\rightarrow$ 0,7

Η παράμετρος w της εξίσωσης 1 ελέγχει τη συνεισφορά κάθε modality. Στο baseline επιλέχθηκε $w = 0,5$ ώστε να δοθεί **ίση βαρύτητα και στα δύο modalities** — η ισοτιμία ήταν σκόπιμη, στοχεύοντας να μην «ευνουθεί» κανένα modality *a priori* χωρίς εμπειρικά δεδομένα. Ωστόσο, τα αποτελέσματα Run 1 έδειξαν ξεκάθαρα: **audio AUC $\approx$ 0,93** έναντι **video AUC $\approx$ 0,57**. Η ισοτιμία οδηγούσε στο να «μολύνει» το αδύναμο video τις αποφάσεις του ισχυρού audio.

Με $w = 0,7$ το audio κυριαρχεί (70%), ενώ το video συνεισφέρει ελάχιστα (30%). Η τιμή δικαιολογείται data-driven από το AUC gap: το audio είναι $\sim 1,6\times$ πιο αξιόπιστο από το video. Επηρεάζει αποκλειστικά τα late fusion πειράματα (12, 14, 16).

4.5 Αποτελέσματα Run 2 και Σύγκριση

Ο πίνακας 2 παρουσιάζει τη μεταβολή AUC μεταξύ Run 1 και Run 2.

Πείραμα	AUC Run 1	AUC Run 2	Δ AUC
Early (HC+LM)	0.9322	0.9324	+0.0002
Audio-only (HC)	0.9274	0.9179	-0.0095
Late (HC+LM)	0.9255	0.9167	-0.0088
Audio-only (W2V)	0.9122	0.9124	+0.0002
Audio-only (HuB)	0.9074	0.9070	-0.0004
Late (W2V+LM)	0.8896	0.9074	+ 0.0178
Late (HuB+LM)	0.8724	0.8758	+0.0034
Early (W2V+LM)	0.7697	0.6014	-0.1683
Early (HuB+LM)	0.6983	0.5529	-0.1454
Video-only (LM)	0.5712	0.5676	-0.0036

Πίνακας 2: Σύγκριση AUC μεταξύ Run 1 (baseline) και Run 2 (τελικό).

Βασικές παρατηρήσεις:

- **Audio-only (01, 02, 03): σταθερά** — Δ AUC $\approx \pm 0,001$. Τα audio-only μοντέλα ήταν ήδη σωστά εκτιμημένα. Η πτώση F1/ACC είναι αναμενόμενη και επιθυμητή.
- **Late fusion 14: μεγαλύτερη βελτίωση +1,8% AUC** — Με $w = 0,7$ το audio κυριαρχεί και η late fusion πλησιάζει την απόδοση audio-only.
- **Early fusion (08, 10): σοβαρή πτώση** — Δ AUC = -0,15 έως -0,17. Το `pos_weight=0,2` αποδείχθηκε υπερβολικά περιοριστικό για early fusion που ενσωματώνει αδύναμα οπτικά χαρακτηριστικά. Το 10 κατέρρευσε εντελώς: F1 = 0,017, προβλέπει τα πάντα ως «real».
- **Video-only (04): τυχαίο και στα δύο runs** — AUC $\approx 0,57$.

Σημαντική παρατήρηση: η πτώση F1/ACC στο Run 2 αποτελεί *θετικό* σημάδι. Στο baseline, τα πειράματα 04, 08, 10 είχαν F1 $\approx 0,98$ ενώ δεν έμαθαν τίποτα (AUC $\approx 0,57-0,77$) — η μετρική εξαπατούσε. Στο Run 2, τα F1/ACC αντικατοπτρίζουν πραγματική απόδοση.

5 Αποτελέσματα

5.1 Σύνοψη Πειραμάτων

Ο πίνακας 3 συνοψίζει τα δέκα πειράματα.

Στρατηγική	Ακουστικά	Οπτικά
Audio-only	Handcrafted (536d)	—
Audio-only	wav2vec2 (768d)	—
Audio-only	HuBERT (768d)	—
Video-only	—	Landmarks (731d)
Early Fusion	Handcrafted (536d)	Landmarks (731d)
Early Fusion	wav2vec2 (768d)	Landmarks (731d)
Early Fusion	HuBERT (768d)	Landmarks (731d)
Late Fusion	Handcrafted (536d)	Landmarks (731d)
Late Fusion	wav2vec2 (768d)	Landmarks (731d)
Late Fusion	HuBERT (768d)	Landmarks (731d)


Πίνακας 3: Σύνοψη δέκα πειραμάτων.

5.2 Κύρια Αποτελέσματα (Run 2)


Ο πίνακας 4 παρουσιάζει τα τελικά αποτελέσματα ταξινομημένα κατά AUC.

Πείραμα	AUC	EER	F1	ACC
Early (HC+LM)	0.9324	0.1591	0.9259	0.8647
Audio-only (HC)	0.9179	0.1621	0.8582	0.7572
Late (HC+LM)	0.9167	0.1703	0.8729	0.7794
Audio-only (W2V)	0.9124	0.1879	0.9288	0.8693
Late (W2V+LM)	0.9074	0.1892	0.9377	0.8848
Audio-only (HuB)	0.9070	0.2003	0.9359	0.8817
Late (HuB+LM)	0.8758	0.1963	0.9388	0.8866
Early (W2V+LM)	0.6014	0.4387	0.9543	0.9129
Video-only (LM)	0.5676	0.4170	0.9865	0.9734
Early (HuB+LM)	0.5529	0.4468	0.0169	0.0309


Πίνακας 4: Τελικά αποτελέσματα Run 2, ταξινομημένα κατά AUC. Με έντονη γραφή το καλύτερο αποτέλεσμα.



Σχήμα 2: Σύγκριση AUC για όλα τα πειράματα (Run 2).



(α') Σύγκριση EER (χαμηλότερο = καλύτερο)



(β') Σύγκριση F1

Σχήμα 3: Σύγκριση EER και F1 για όλα τα πειράματα. Η υψηλή F1 σε πειράματα με χαμηλό AUC (π.χ. 04, 08) αποκαλύπτει το πρόβλημα ανισορροπίας κλάσεων.


5.3 Σύγκριση Audio Extractors

Στα audio-only πειράματα: **Handcrafted (0,918) > wav2vec2 (0,912) > HuBERT (0,907)**. Η ελαφρά υπεροχή των handcrafted χαρακτηριστικών υποδηλώνει ότι οι εξειδικευμένοι δείκτες (MFCC, F0, ZCR) συλλαμβάνουν κρίσιμα φωνητικά χαρακτηριστικά για deepfake ανίχνευση πέρα


από αυτά που κωδικοποιούν τα γενικά SSL μοντέλα χωρίς fine-tuning.

5.4 Fusion vs Unimodal


- **Early fusion HC+LM (06, AUC=0,932)**: καλύτερο overall. Τα handcrafted features είναι αρκετά ισχυρά ώστε να αντέχουν την ενσωμάτωση αδύναμων landmark features στο κοινό feature vector.
- **Early fusion W2V+LM (08) και HuB+LM (10)**: AUC 0,60 και 0,55 αντίστοιχα — η ενσωμάτωση άχρηστης οπτικής πληροφορίας στο κοινό vector αποσταθεροποιεί τα SSL-based μοντέλα αντί να τα βοηθά.
- **Late fusion (12–16)**: ισορροπημένη προσέγγιση — πλησιάζει την απόδοση audio-only χωρίς την αποσταθεροποίηση της early fusion.
- **Video-only (04, AUC=0,568)**: ουσιαστικά τυχαία ταξινόμηση — τα landmarks (γεωμετρία προσώπου) δεν αρκούν για ανίχνευση deepfake.




(α') Audio-only Handcrafted (01), AUC=0,918



(β') Early Fusion HC+LM (06), AUC=0,932



(γ') Late Fusion W2V+LM (14), AUC=0,907



(δ') Video-only Landmarks (04), AUC=0,568


Σχήμα 4: ROC curves για τέσσερα αντιπροσωπευτικά πειράματα.

5.5 Ανάλυση ανά Κατηγορία


Ο πίνακας 5 και το σχήμα 5 παρουσιάζουν την ακρίβεια ανά κατηγορία για όλα τα πειράματα.

Πείραμα	RVRA	RVFA	FVRA	FVFA
Audio-only (HC)	0.960	0.989	0.513	0.963
Audio-only (W2V)	0.760	1.000	0.759	0.970
Audio-only (HuB)	0.760	1.000	0.783	0.973
Video-only (LM)	0.013	1.000	0.996	0.996
Early (HC+LM)	0.813	1.000	0.725	0.990
Early (W2V+LM)	0.187	0.841	0.914	0.950
Early (HuB+LM)	0.973	0.011	0.009	0.008
Late (HC+LM)	0.947	0.989	0.555	0.969
Late (W2V+LM)	0.747	1.000	0.788	0.976
Late (HuB+LM)	0.760	1.000	0.793	0.974


Πίνακας 5: Ακρίβεια (accuracy) ανά κατηγορία. RVRA=RealVideo-RealAudio, RVFA=RealVideo-FakeAudio, FVRA=FakeVideo-RealAudio, FVFA=FakeVideo-FakeAudio.



Σχήμα 5: Heatmap ακρίβειας ανά κατηγορία και πείραμα.



(α') Ακρίβεια ανά κατηγορία — πείραμα 06 (καλύτερο)



(β') Confusion matrix — πείραμα 06

Σχήμα 6: Ανάλυση του καλύτερου πειράματος (06 Early Fusion HC+LM, AUC=0,932).

Βασικά ευρήματα:


- **FVRA = πιο δύσκολη κατηγορία για audio-based μοντέλα:** ακρίβεια 51,3%–78,8%. Ψεύτικο πρόσωπο με πρωτότυπο ήχο — το audio δεν φέρει κανένα artifact.
- **RVFA = πιο εύκολη κατηγορία:** ακρίβεια 98,9%–100% — ο συνθετικός ήχος αναγνωρίζεται αμέσως.
- **Video-only (04) — RVRA = 1,3%:** το μοντέλο ταξινομεί σχεδόν όλα τα αληθινά βίντεο ως «fake», επιβεβαιώνοντας ότι τα landmarks δεν διαχωρίζουν real από fake πρόσωπα.
- **10_early_hubert — κατάρρευση:** αντεστραμμένη κατανομή (RVRA=97,3% αλλά FVFA=0,8%) — το μοντέλο ταξινομεί σχεδόν τα πάντα ως «real», εντελώς αντίθετη αστοχία από τα υπόλοιπα μοντέλα.

6 Ερμηνευσιμότητα


6.1 Audio Temporal Heatmap

Μέθοδος. Εφαρμόζεται sliding window στο ακουστικό σήμα: παράθυρο 0,5 s, βήμα 0,1 s. Για κάθε παράθυρο εξάγονται ξεχωριστά τα χαρακτηριστικά και υπολογίζεται η πιθανότητα $P(\text{fake})$. Αποτέλεσμα: χρονική χαρτογράφηση των «ύποπτων» τμημάτων ήχου.

Αποτελέσματα. Το σχήμα 7 παρουσιάζει τα heatmaps για ένα fake δείγμα (FakeVideo-FakeAudio, 4,7 s) και ένα real δείγμα (RealVideo-RealAudio, 10,24 s).



(α') Fake δείγμα: $P(\text{fake}) > 0,87$ σε όλα τα παράθυρα



(β') Real δείγμα: ανομοιογενές, τμήματα με $P(\text{fake}) < 0,3$


Σχήμα 7: Audio temporal heatmap για fake και real δείγμα (audio-only, wav2vec2).

Στο fake δείγμα, το μοντέλο ανιχνεύει artifact σε κάθε χρονικό παράθυρο ($P(\text{fake}) > 0,87$ παντού) — ο συνθετικός ήχος εμφανίζει συνεπή τεχνητά χαρακτηριστικά σε όλη τη διάρκεια. Στο real δείγμα παρατηρούνται τμήματα με χαμηλή πιθανότητα (π.χ. $t = 0,75$ s: $P = 0,275$, $t = 3,45-3,75$ s: $P = 0,097-0,125$), ωστόσο η πλειοψηφία παραμένει υψηλή — το μοντέλο ταξινομεί τελικά το δείγμα ως «fake» (ψευδώς θετικό).


6.2 Visual Region Ablation

Μέθοδος. Για κάθε περιοχή προσώπου (μάτια, jaw, φρύδια, στόμα), τα αντίστοιχα landmarks μηδενίζονται και μετράται η μεταβολή $\Delta P(\text{fake})$. Μεγάλο drop υποδηλώνει κρίσιμη περιοχή για την απόφαση.

Αποτελέσματα. Το σχήμα 8 παρουσιάζει τα αποτελέσματα για fake (early fusion) και real (late fusion) δείγμα.



(α') Fake: όλες οι περιοχές low impact ($\Delta P < 0,001$)



(β') Real: Jaw και Brows με υψηλό impact

Σχήμα 8: Visual region ablation για fake (early fusion) και real (late fusion) δείγμα.

Στο fake δείγμα (early fusion, $P_{\text{base}} = 1,00$), η μηδένιση οποιασδήποτε περιοχής δεν επηρεάζει ουσιαστικά την απόφαση — αναμενόμενο, καθώς το audio κυριαρχεί απόλυτα στην early fusion. Στο real δείγμα (late fusion, $P_{\text{base}} = 0,632$), η visual υπο-μηχανή βασίζεται κυρίως στο **jaw** ($\Delta P = +0,059$, HIGH impact) και τα **φρύδια** (αντίστροφη επίδραση: $\Delta P = -0,077$, αφαίρεσή τους *αυξάνει* P , HIGH impact).

7 Συμπεράσματα & Μελλοντική Εργασία

7.1 Συμπεράσματα

1. **To audio modality κυριαρχεί** — AUC 0,91–0,93 σταθερά σε όλες τις μεθόδους εξαγωγής χαρακτηριστικών. Η ανίχνευση του deepfake ήχου είναι σαφώς πιο εφικτή από την ανίχνευση του deepfake προσώπου με γεωμετρικά χαρακτηριστικά.
2. **Τα landmark features ανεπαρκή** (AUC $\approx 0,57 \approx$ τυχαίο). Τα landmarks αναπαριστούν μόνο τη *γεωμετρία* του προσώπου, ενώ τα deepfakes εμφανίζουν artifacts στο *texture* (θόλωμα ορίων, ανομοιόμορφη υφή δέρματος, ατέλειες στις βλεφαρίδες).
3. **Early fusion με αδύναμα visual features = αστάθεια**: η ενσωμάτωση άχρηστης πληροφορίας στο κοινό feature vector αποσταθεροποιεί την εκπαίδευση (AUC 0,60 / κατάρρευση) αντί να τη βοηθήσει.
4. **Late fusion με $w = 0,7$ = η πλέον ισορροπημένη πολυτροπική προσέγγιση**: επιτρέπει στο audio να κυριαρχεί χωρίς να αποκλείεται εντελώς η οπτική πληροφορία, και χωρίς τον κίνδυνο αστάθειας της early fusion.
5. **Ανισορροπία κλάσεων = κρίσιμο μεθοδολογικό ζήτημα**: `pos_weight=0,2` και `WeightedRandomSampler` είναι απαραίτητα για σωστή εκπαίδευση. Το AUC είναι η μόνη αξιόπιστη μετρική αξιολόγησης — F1/ACC παραπλανούν σε ακραία ανισόρροπα datasets.
6. **FakeVideo-RealAudio = το δυσκολότερο σενάριο** για audio-based συστήματα: ακρίβεια 51%–79%. Όταν το πρόσωπο είναι ψεύτικο αλλά ο ήχος αυθεντικός, τα audio-only μοντέλα αδυνατούν να ανιχνεύσουν — απαιτείται ισχυρό οπτικό modality.

7.2 Μελλοντική Εργασία

Η κρίσιμη επέκταση είναι η αντικατάσταση των landmark features με **Xception** visual features. Το Xception χρησιμοποιεί depthwise separable convolutions και εξάγει **2048-dim texture embeddings** μέσω crop προσώπου και forward pass χωρίς το τελευταίο classification head. Σε αντίθεση με τα landmarks, αυτή η αναπαράσταση αιχμαλωτίζει τα texture artifacts που χαρακτηρίζουν τα deepfakes.

Αναμένεται σημαντική βελτίωση video-only AUC: $0,57 \rightarrow 0,75\text{--}0,85^+$. Με ισχυρά οπτικά χαρακτηριστικά:

- Η early fusion θα μπορούσε πλέον να αποδώσει πραγματικά συμπληρωματική πληροφορία.
- Η κατηγορία FakeVideo-RealAudio θα γινόταν αντιμετωπίσιμη μέσω του οπτικού modality.
- Η late fusion θα εξισορροπούσε καλύτερα τα δύο modalities χωρίς την ανάγκη υπερβολικής βαρύτητας ($w = 0,7$) στο audio.

Επιπλέον, για την αποφυγή απότομης μείωσης διαστάσεων ($2048d \rightarrow 256d$ απευθείας στο πρώτο MLP layer), θα προστεθεί ένα ενδιάμεσο linear layer (π.χ. $2048 \rightarrow 512$) πριν το classifier, δίνοντας στο μοντέλο χώρο να μάθει σταδιακή αναπαράσταση.

Η υλοποίηση υπάρχει ήδη στο project. Η εκτέλεσή της δεν ολοκληρώθηκε λόγω του υψηλού υπολογιστικού κόστους του frame-by-frame Xception inference στο σύνολο των 21.566 βίντεο.

Αναφορές

- [1] H. Khalid, S. Tariq, M. Kim, S. S. Woo, “FakeAVCeleb: A Novel Audio-Video Multimodal Deepfake Dataset,” *NeurIPS Datasets and Benchmarks*, 2021. arXiv:2108.05080.